DOCUMENTACIÓN TÉCNICA DE SOPORTE - INGENIERÍA DE DATOS

Herramientas cubiertas: Apache Airflow y dbt (Data Build Tool)

1. INTRODUCCIÓN A APACHE AIRFLOW

Apache Airflow es una plataforma de código abierto para programar, orquestar y monitorear flujos de trabajo de ingeniería de datos. Los flujos se definen como Grafos Acíclicos Dirigidos (DAGs) escritos en lenguaje Python.

2. CÓMO CONFIGURAR UN DAG EN AIRFLOW

Para configurar y estructurar un DAG básico en Apache Airflow, se deben seguir los siguientes componentes esenciales en un archivo Python dentro de la carpeta dags:

- Importaciones: Se deben importar la clase DAG, los operadores necesarios (como PythonOperator o BashOperator) y el módulo datetime para el manejo de fechas y reintentos.

- Definición de argumentos por defecto (default_args): Permiten configurar parámetros globales para todas las tareas del DAG, tales como el propietario (owner), la fecha de inicio (start_date), la cantidad de reintentos (retries) y el tiempo de espera entre reintentos (retry_delay).

- Instanciación del DAG: Se crea el objeto DAG utilizando un identificador único (dag_id), los argumentos por defecto y el intervalo de ejecución (schedule_interval o schedule).

Ejemplo de estructura de código de un DAG:

```
from datetime import datetime, timedelta

from airflow import DAG

from airflow.operators.bash import BashOperator


default_args = {
```

```
    'owner': 'data_engineer',
    'depends_on_past': False,
    'start_date': datetime(2026, 1, 1),
    'retries': 1,
    'retry_delay': timedelta(minutes=5),
}

dag = DAG(
    'primer_dag_ejemplo',
    default_args=default_args,
    description='Un DAG simple de prueba en Airflow',
    schedule_interval='@daily',
)

tarea_1 = BashOperator(
    task_id='saludar_tarea',
    bash_command='echo "Hola Mundo desde Airflow"',
    dag=dag,
)
```

3. COMANDOS BÁSICOS DE DBT (DATA BUILD TOOL)

dbt es una herramienta de transformación de datos que permite a los ingenieros y analistas transformar datos en el almacén (warehouse) mediante el uso de sentencias SQL select simples y modulares.

Los comandos fundamentales de la interfaz de comandos (CLI) de dbt son:

- dbt init [nombre_proyecto]: Inicializa una nueva estructura de proyecto dbt con las carpetas y archivos de configuración estándar (como dbt_project.yml).

- dbt debug: Verifica la conexión del perfil de dbt con la base de datos o data warehouse y valida que el archivo profiles.yml esté configurado correctamente.

- dbt run: Ejecuta los modelos SQL construidos en el proyecto, materializándolos como tablas o vistas dentro del almacén de datos.

- dbt test: Ejecuta pruebas automatizadas (tests) sobre los modelos, como validaciones de unicidad (unique) y valores no nulos (not_null).

- dbt docs generate y dbt docs serve: Genera y levanta un servidor web local con la documentación interactiva y el linaje visual (lineage graph) de los modelos de datos.

4. POLÍTICAS DE SOPORTE Y LIMITACIONES

Este asistente proporciona respuestas estrictamente basadas en la documentación oficial indexada de Airflow y dbt. Si una consulta del usuario involucra tecnologías ajenas a este repositorio, herramientas privativas no soportadas, o información que no se encuentre dentro de los fragmentos de conocimiento cargados, el asistente indicará explícitamente sus limitaciones y abstendrá de generar alucinaciones técnicas.